SKKU Course Agent
모델 선택 요약

2026년 11월 10일 개정 | 공개 비교 및 비용 산정 기준 2026년 11월 3일

추천안은 텍스트 답변에 Claude Haiku 5.5 medium을 시험하고, 실시간 음성과 자료 검색은 기존 Qwen으로 유지하는 구성이다.

1 현재 Qwen 성능

현재 사용 모델	학교 서버 개발 실험 p50	측정 범위
텍스트 Qwen3.8 27B	4.58초	생성 완료 비교 실험 현재 텍스트 운영 실측 아님
음성 Qwen3.5 9B	응답 준비 7.30초 첫 오디오 생성 10.02초	강의자료 기반 준비 24턴 첫 오디오는 합성 음성 3건

27B의 4.58초는 추론을 끈 동일 음성 정책 실험값이다. 9B의 첫 오디오 시간은 발화 종료 검출 후 생성까지이며, 브라우저 재생은 제외했다. 상세 조건은 부록 A에 정리했다.

2 Haiku 적용 시 성능과 비용 차이

공개 비교 지표	Qwen3.8 27B xhigh	Haiku 5.5 medium	Haiku 적용 차이
첫 답변까지 대기	52.32초	14.14초	38.18초 단축
답변 500토큰 출력 구간	12.08초	2.84초	9.24초 단축
전체 LLM 참고 시간	64.40초	16.98초	47.42초 단축
AA 지능 지수	20	25	+5점

AA의 11월 3일 공개 비교에서 전체 시간은 약 74% 짧았다. 위 표는 학교 서버의 실제 단축 시간을 뜻하지 않는다. [25]

월 활성 1,000명 기준 추가 API 비용은 중앙값 시나리오 $14.40, 기존 평균 시나리오 $64다. Qwen 단독의 외부 API 과금은 $0이며, 기존 서버 운영비는 두 구성에 공통이다. [29]

3 추천 복합 구성

텍스트 답변과 다음 힌트는 Haiku 5.5 medium, 실시간 음성 답변은 Qwen 9B를 사용한다. 자료 검색과 음성 인식 및 합성은 현재 구성을 유지하고, 학생 답 평가는 답변 생성에 포함해 별도 Sonnet 호출을 추가하지 않는다.

같은 강의자료와 질문으로 한국어 답변의 근거 충실도와 힌트 품질, 지연을 확인한 뒤 채택한다. 사용량과 단가, 추가 기능 예산은 뒤의 부록을 참고한다.

부록 A 현재 API 구성과 학교 서버 실험

기능	현재 API와 모델	성능 또는 확인 사양	API 사용료
텍스트 답변	학교 Model Server Qwen3.8-27B	참고 실험 p50 4.583초	토큰당 과금 없음
음성 답변 자료 판독	학교 Model Server Qwen3.5-9B	참고 실험 p50 3.054초	토큰당 과금 없음
강의자료 검색	Qwen3-VL-Embedding-2B	2048차원 사양 검색 정확도 미측정	토큰당 과금 없음
음성 인식	외부 Speech Server Qwen ASR	단어 오류율 WER 미측정	별도 건당 과금 없음
음성 합성	외부 Speech Server Qwen TTS Sohee Korean	음성 품질 MOS 미측정	별도 건당 과금 없음
보충 웹 검색	자체 호스팅 SearXNG	검색 지연 p95 미측정	자체 호스팅 비용

선택값은 local_qwen과 local_cascade이며, 상용 유료 API는 기본 경로가 아니다. 자체 호스팅의 GPU와 서버 운영비는 별도다. [L1] [20] [21] [22] [23]

p50은 2026년 9월 9일 동일 음성 정책의 개발 실험으로 모델당 36회, thinking 비활성, 출력 한도 320토큰이다. ASR, 실제 검색, TTS와 재생은 제외했다. 현재 텍스트 경로 성능이나 운영 SLA는 아니다. [L2]

학교 서버 개발 실험의 측정 범위

기존 개발 실험	관측값	측정 범위
Qwen 9B와 27B 비교	9B 3.054초 27B 4.583초	모델당 36회 완료 중앙값 thinking 비활성 출력 한도 320
Qwen 9B 실제 자료 응답	7.296초	24턴 응답 준비 중앙값 ASR와 TTS 제외
Qwen 9B 첫 음성	10.017초	합성 3건 VAD 종료부터 첫 오디오 생성까지 중앙값

첫 행은 기존 비교 파일, 뒤 두 행은 자료 사전 판독 적용 실험의 관측값이다. 현재 텍스트 27B thinking 경로의 최신 실측은 아니고, 첫 음성은 브라우저 재생을 제외한 값이다. [L2, L4]

따라서 공개표의 47.4초를 실제 학교 서비스의 절감 시간으로 발표하면 안 된다. 현재 음성 9B가 더 빠를 가능성이 있어 음성 경로는 유지한다. 전체 서비스 비교에는 ASR, 자료 검색, LLM, TTS 및 재생 시간을 같은 입력에서 각각 측정해야 한다.

부록 B 공개 성능 비교의 측정 조건

AA의 2026년 11월 3일 조회값을 보존했다. 아래 비교는 약 10,000 입력 토큰과 답변 500토큰 조건이며, 비용 산정의 입력 4,000토큰과 청구 출력 800토큰 조건과 다르다. 연결된 평가 페이지의 수치는 조회 시점에 따라 갱신된다. [25] [27]

공개 비교 지표	Qwen3.8 27B xhigh	Haiku 5.5 medium	공개값 차이
AA 지능 지수	20	25	+5점
첫 답변까지 대기 입력과 추론 및 대기 포함	52.32초	14.14초	38.18초 짧음
답변 500토큰 출력 구간	12.08초	2.84초	9.24초 짧음
LLM 전체 참고 시간	64.40초	16.98초	47.42초 짧음

이 공개 조건에서는 합계가 약 64.4초에서 17.0초로, 약 47.4초 또는 73.6% 짧다. 출력 구간은 공개 합계에서 첫 답변 대기를 뺀 계산값이다. 두 모델의 추론 설정은 서로 다르며, 지수 25는 기존 성능 표의 Haiku max 36과 같은 설정이 아니다. [25]

첫 답변 대기는 순수 추론 시간만이 아니라 입력 처리, 네트워크와 큐 대기를 포함한다. Haiku의 내부 추론을 별도 초 단위로 분리할 근거는 없으므로 그 부분을 임의로 계산하지 않았다. [27]

판단 기준

예산 우선 텍스트 교체 후보로 Haiku medium을 시험하되, 교수자의 한국어 근거 충실성 및 힌트 평가를 통과해야 채택한다. 현재 코드의 공급사 어댑터 호환성 보완도 필요하다. 이번 보완에서는 모델 설정 변경이나 유료 API 실측을 실행하지 않았다.

부록 C 중앙값과 평균 기준의 월 사용량

기존 보고서의 1인 월 80턴에 중앙값을 참고한 월 18턴을 추가했다. 두 시나리오 모두 한 턴을 질문과 답변 1회로 보고, 입력 4,000토큰과 추론을 포함한 청구 출력 800토큰을 사용한다고 가정한다.

1인 한 달의 토큰 사용량

사용량 기준	월 질의응답	입력 토큰	청구 출력 토큰	합계 토큰
중앙값 참고	18회	72,000	14,400	86,400
기존 평균 참고	80회	320,000	64,000	384,000

1000명 한 달의 산정량

사용량 기준	총 질의응답	총 입력 토큰	총 청구 출력 토큰
중앙값 참고	18,000회	72,000,000	14,400,000
기존 평균 참고	80,000회	320,000,000	64,000,000

1,000명은 등록 인원이나 동시 접속자가 아니라 월간 활성 사용자 1,000명을 뜻한다. 입력에는 시스템 지시문과 강의자료 및 대화 이력을 포함한다. 여러 유료 생성 호출이 있으면 합산 사용량이 위 토큰 가정 안에 들어가야 한다.

사용 횟수의 근거

Epoch AI의 미국 YouGov 패널에서 2025년 12월 활성 사용자당 월 메시지는 중앙값 36개, 평균 158개였다. 질문과 답변을 각각 1개 메시지로 단순화하면 중앙값은 약 18턴, 평균은 약 79턴이다. 기존 보고서와의 비교를 위해 평균 참고 시나리오는 반올림한 80턴을 유지했다. [6]

이 조사는 한국 대학생 실측이 아니고, 동의한 패널의 자료를 사용한다. 또한 회당 입력 4,000과 청구 출력 800토큰은 조사 결과가 아닌 RAG 예산 가정이다. 따라서 월 86,400과 384,000토큰을 사람의 보편적인 실측 사용량으로 표현하면 안 된다.

중앙값과 평균의 해석

중앙값은 대표적인 한 명의 사용 빈도를 보는 참고값이다. 조사에서는 상위 10%가 전체 질문의 63%를 차지했다. 중앙값 사용량을 1,000명 모두에게 적용하면 헤비 사용자가 만드는 비용을 과소추정할 수 있으므로, 다음 표의 중앙값 열은 낮은 사용량의 비교 시나리오로 읽는다. [6]

전체 예산은 평균 참고 시나리오를 함께 검토하고 실제 운영 로그로 보정한다. 80턴도 사용량 상한은 아니다. 두 시나리오의 입력과 출력은 모두 18 / 80 = 22.5% 관계이므로, 같은 단가에서 중앙값 참고 비용은 기존 평균 참고 비용보다 77.5% 작다.

부록 D 모델별 1000명 월 API 비용

입력과 출력 단가는 각각 100만 토큰당 금액이며, 두 비용 열은 월간 활성 사용자 1,000명의 텍스트 LLM API 총액이다. 동일 단가와 회당 토큰량에서 월 18회와 80회를 비교했다. [1] [2] [3] [4] [5]

모델	입력 단가 100만 토큰당	출력 단가 100만 토큰당	중앙값 참고 18회 월 총액	기존 평균 참고 80회 월 총액
Claude Haiku 5.5	$0.10	$0.50	$14.40	$64
GPT-6 Luna	$0.10	$0.50	$14.40	$64
DeepSeek V4.1 Flash 1017	$0.30	$1.20	$38.88	$172.80
Gemini 3.5 Flash-Lite	$0.30	$2.50	$57.60	$256
Gemini 3.8 Flash	$0.75	$3.75	$108	$480
GPT-6.1 Terra	$1	$5	$144	$640
Grok 4.7	$2	$6	$230.40	$1,024
Claude Sonnet 5.5	$2	$10	$288	$1,280
GPT-6.1 Sol	$2	$10	$288	$1,280
Gemini 4 Argon	$2	$10	$288	$1,280
Claude Opus 5.5	$4	$20	$576	$2,560
GPT-6 Astra	$10	$50	$1,440	$6,400

중앙값 참고 월 총액 = 72 × 입력 단가 + 14.4 × 출력 단가

기존 평균 참고 월 총액 = 320 × 입력 단가 + 64 × 출력 단가

중앙값 열은 실제 사용자 분포를 합산한 총비용 예측이 아니라, 모든 사용자가 18턴을 사용한다고 둔 비교값이다. 헤비 사용자까지 포함한 예산 검토에는 평균 열도 함께 사용한다.

가격 적용 조건

Gemini 3.8 Flash는 2026년 12월까지 할인이다. 2027년 1월부터 입력 $1.50와 출력 $7.50를 적용하면 중앙값 / 평균 월 총액은 $216 / $960이다. Argon은 2026년 11월까지 할인이고 12월부터 입력 $4와 출력 $20, 두 총액은 $576 / $2,560이다. [3]

DeepSeek 표는 피크와 비캐시 요금이다. 비피크 입력 $0.15와 출력 $0.60이면 중앙값 / 평균 월 총액은 $19.44 / $86.40이다. 실제 총액은 사용 시간에 따라 달라진다. [4]

Haiku는 요청 입력 10만 토큰 이하, Grok은 20만 토큰 미만 구간이다. 무료 크레딧, 캐시 할인, Batch, 장문과 지역 할증, 별도 검색 도구, 음성 API, 세금과 환율은 계산에서 제외했다.

각 상용 모델이 해당 텍스트 생성량을 담당할 때의 비용이며 학교 GPU와 앱 및 DB 운영비는 제외했다. Qwen 자체 서빙은 외부 토큰 API 과금이 없지만 인프라 비용은 발생한다. 한국어 토큰화와 실제 추론량은 모델마다 다를 수 있다.

부록 E 유료 모델의 공개 성능 지표

Artificial Analysis Intelligence Index v5.0과 출력 속도다. 2026년 11월 3일 각 모델 페이지를 다시 확인했다. 지수는 높을수록 좋으며 정답률 백분율이 아니다. [7]

모델과 출처	지능 지수	출력 토큰 초당	평가 추론 설정
Claude Opus 5.5 [18]	58	94.7	max with fallback
GPT-6 Astra [19]	57	71.6	max
GPT-6.1 Sol [16]	55	91.3	max
Claude Sonnet 5.5 [15]	54	138.7	max with fallback
GPT-6.1 Terra [13]	51	110.4	max
Gemini 4 Argon [17]	50	83.3	high
Claude Haiku 5.5 [8]	36	233.8	max
Grok 4.7 [14]	35	80.5	xhigh
DeepSeek V4.1 Flash 1017 [10]	32	170.5	max
Gemini 3.8 Flash [12]	31	131.3	high
GPT-6 Luna [9]	28	117.2	max
Gemini 3.5 Flash-Lite [11]	12	423.3	기본

출력 속도는 생성 시작 후의 처리량이며, 첫 유효 답변까지의 대기와 검색 및 음성 처리 시간은 아니다. 지수는 영어 중심 종합 평가로 한국어 교수법 성능과는 구분한다. high와 max는 같은 계산량이 아니고 max with fallback은 평가기관의 표기다.

비용 표의 청구 출력 800토큰은 예산 가정이다. 이 예산 안에서 위 고추론 성능을 그대로 얻는다는 의미는 아니다. 이번 문서 정리에서는 유료 API를 호출하지 않았다.

부록 F 추천 구성의 비용 산정

가격과 공개 성능을 함께 고려한 1차 검증 후보는 음성 Qwen 9B를 유지하고, 텍스트 답변만 Claude Haiku 5.5 medium으로 바꾸는 구성이다. 현재 비교 후보 안에서의 예산 우선 제안이며, 한국어 교수 품질을 통과한 최적 구성이 확정됐다는 뜻은 아니다.

처리 부분	Qwen 단독	가성비 우선 검증 후보
텍스트 답변과 다음 힌트	Qwen3.8-27B	Claude Haiku 5.5 medium
실시간 음성 답변	Qwen3.5-9B	Qwen3.5-9B 유지
자료 검색과 음성 입출력	Qwen 임베딩 및 ASR TTS	동일 Qwen 경로 유지
학생 답 평가	답변 모델 안에서 판단	Haiku 답변 안에서 판단 별도 Sonnet 평가 호출 없음

1000명 한 달의 API 비용 차이

구성	중앙값 참고 월 유료 API	기존 평균 참고 월 유료 API
Qwen 단독	$0	$0
가성비 핵심 구성	$14.40	$64
핵심 구성과 리포트 및 자료 판독	$28.80	$78.40

핵심 구성은 텍스트 월 18,000턴 / 80,000턴, 턴당 입력 4,000과 청구 출력 800토큰 기준이다. 음성은 기존 자체 서빙 비용으로 유지한다. 여러 유료 생성 호출이 있으면 한 턴의 합산 토큰량이 위 가정에 들어가야 한다. [29]

마지막 행은 두 경우 모두 주간 리포트 $5.40와 자료 재판독 $9를 더했다. 자료 판독과 리포트는 대화의 직렬 호출과 분리한다. Argon 할인 종료 후 이 행은 중앙값 참고 $37.80, 기존 평균 참고 $87.40이다.

동일한 기존 인프라비 C에서 총액은 표의 API 비용에 C를 더한 금액이다. GPU 축소 절감은 반영하지 않았으므로 Qwen 단독보다 총비용이 절감된다는 뜻은 아니다.

추론 예산과 비교 한계

추론을 포함한 청구 출력이 턴당 800토큰이면 중앙값 / 평균 월 $14.40 / $64, 2,000토큰이면 $25.20 / $112, 4,000토큰이면 $43.20 / $192다. 입력과 각 시나리오의 턴 수는 유지했다. 산술 예시이며 청구액의 신뢰구간은 아니다.

부록 B의 공개 지연과 품질은 별도 평가 조건이다. 위 예산에서 같은 성능이 보장되지 않는다. 부록 G의 $266.40 / $1,134.40은 Sonnet 별도 평가를 추가한 다른 견적이므로 이 장의 비용과 합산하지 않는다.

부록 G 추가 기능의 별도 견적

현재 Qwen 서비스에 아래 세 기능을 추가하는 경우의 예산이다. 학생 답 평가는 대화 횟수에 비례하며, 자료 페이지 수와 리포트 횟수는 두 시나리오에서 동일하게 유지한다. 앞의 상용 모델별 텍스트 총액을 여기에 중복해서 더하지 않는다.

추가할 기능	유료 API 후보	중앙값 참고 월 추가 총액	기존 평균 참고 월 추가 총액
학생 답 이해도 판단	Claude Sonnet 5.5	$252	$1,120
표와 수식 자료 판독	Gemini 4 Argon	$9	$9
주간 학습 리포트	Claude Haiku 5.5	$5.40	$5.40
합계	**위 세 기능**	**$266.40**	**$1,134.40**

월 추가 API 총액은 중앙값 참고 $266.40, 기존 평균 참고 $1,134.40이다. 각각 기존 GPU와 앱 및 DB 운영비가 별도로 든다.

학생 답 이해도 판단

추가 목적은 학생의 단순 동의를 정답으로 칭찬하는 오류를 줄이고, 오개념과 다음 힌트 단계를 점검하는 것이다. 기존 실험에서 확인된 실패 유형을 대상으로 Sonnet을 검증 후보로 둔다. 개선 효과가 확인된 상태는 아니다. [L2] [2]

한 번에 학생 답, 평가 기준과 근거를 포함한 입력 2,000토큰과 추론을 포함한 청구 출력 1,000토큰을 가정했다. 중앙값 참고는 월 18,000회로 입력 3,600만과 출력 1,800만 토큰, 기존 평균 참고는 월 80,000회로 입력 1억6천만과 출력 8천만 토큰이다.

표와 수식 자료 판독

추가 목적은 복잡한 강의자료의 표, 그림과 수식에서 Qwen 판독 결과를 검토하는 것이다. Gemini Argon의 이미지와 PDF 입력을 검증 후보로 둔다. [24]

교수자 자료 월 1,000페이지, 페이지당 입력 2,000토큰과 청구 출력 500토큰을 가정했다. 페이지 수는 학생 수와 별개이며, 실제 이미지 토큰은 해상도와 내용에 따라 달라진다. Argon 할인 종료 후 이 기능은 월 $18이다. [3]

주간 학습 리포트

추가 목적은 요약된 학습 기록에서 취약 개념과 다음 학습 항목을 정리하는 것이다. Haiku를 저비용 후보로 두고, 1인 월 4회로 총 4,000개 리포트를 가정했다. 리포트당 요약된 로그 입력 6,000토큰과 청구 출력 1,500토큰이다. [2]

2026년 12월부터 세 기능의 추가 API 합계는 중앙값 참고 월 $275.40, 기존 평균 참고 월 $1,143.40이다. 모든 수치는 기능 설계용 추정이며 실측 청구 예측은 아니다. 도입 전에는 동일 자료와 교수자 채점으로 정확성 및 지연을 검증한다.

출처

비용표와 공개 벤치마크는 2026년 11월 3일 보고서의 기준을 유지했다. 2026년 11월 10일 개정에서는 현재 모델 설정과 Haiku 단가를 확인하고 보고서의 순서를 재구성했다. 새 성능 실험이나 트래픽 측정은 하지 않았다.

[1] OpenAI Standard API 가격
[2] Anthropic API 가격
[3] Gemini Standard API 가격
[4] DeepSeek 모델과 시간대별 가격
[5] xAI Grok API 가격
[6] Epoch AI 월간 메시지 사용량 연구
[7] Artificial Analysis Intelligence Index 평가 방법
[8] AA Claude Haiku 5.5
[9] AA GPT-6 Luna
[10] AA DeepSeek V4.1 Flash 1017
[11] AA Gemini 3.5 Flash-Lite
[12] AA Gemini 3.8 Flash
[13] AA GPT-6.1 Terra
[14] AA Grok 4.7
[15] AA Claude Sonnet 5.5
[16] AA GPT-6.1 Sol
[17] AA Gemini 4 Argon
[18] AA Claude Opus 5.5
[19] AA GPT-6 Astra
[20] Qwen3.8 27B 모델과 라이선스
[21] Qwen3.5 9B 모델과 라이선스
[22] Qwen3 VL Embedding 2B 모델과 라이선스
[23] SearXNG 공식 문서
[24] Gemini Argon 지원 입력과 기능
[25] AA Haiku medium과 Qwen 27B xhigh 직접 비교
[26] AA Haiku 5.5 medium 평가 설정
[27] AA API 지연과 출력 시간 측정 방법
[28] AA Qwen3.8 27B xhigh 평가 설정
[29] Haiku 5.5 추론 설정과 공식 단가

저장소 근거

[L1 현재 설정]
/Users/cjfwn44/Documents/SKKU_AI_Agent/apps/backend/app/core/config.py

[L2 기존 성능 실험]
/Users/cjfwn44/Documents/SKKU_AI_Agent/docs/evaluations/voice-comparison-artifact.json

[L3 음성 API 연결]
/Users/cjfwn44/Documents/SKKU_AI_Agent/apps/backend/app/services/model_server/speech_client.py

[L4 자료와 음성 실험]
/Users/cjfwn44/Documents/SKKU_AI_Agent/docs/evaluations/voice-precomputed-report-20260911.md